

Libro de Códigos

Conjunto limpio de establecimientos educativos de Guatemala

Este documento corresponde a las actividades 9 y 10 del Proyecto 1: generación del conjunto limpio y documentación de todas las variables finales.

Campo	Valor
Nombre	DATOS_LIMPIOS.csv
Versión	1.0
Fecha de generación	23 de julio de 2026
Fecha de extracción	No documentada en los archivos proporcionados; pendiente de confirmación del grupo.
Fuente	MINEDUC - Búsqueda de centros educativos autorizados y carreras
URL	http://www.mineduc.gob.gt/BUSCAESTABLECIMIENTO_GE/
Cobertura	Establecimientos educativos de Guatemala hasta nivel diversificado
Registros crudos	9,728
Registros limpios	9,707
Variables finales	19
Duplicados exactos eliminados	21
Posibles duplicados conservados	1,451
Codificación	UTF-8 con BOM
Separador	Coma

Definición de variables

Variable	Descripción	Tipo	Dominio	Valores	Tratamiento	Derivada	Observaciones
codigo_establecimiento	Código oficial del servicio educativo autorizado.	Texto	NN-NN-NNNN-NN o vacío	Códigos únicos del MINEDUC	Se eliminaron espacios; se validó el patrón; no se imputaron códigos faltantes.	No	Identificador casi único.
distrito	Código del distrito de supervisión educativa.	Texto	Código alfanumérico o vacío	Valores observados	Se normalizaron espacios.	No	Se conserva como texto.
departamento	Departamento donde se ubica el establecimiento.	Texto categórico	22 departamentos o vacío	22 categorías	Mayúsculas, espacios simples y validación de catálogo.	No	Un registro conserva valor vacío.
municipio	Municipio donde se ubica el establecimiento.	Texto categórico	Municipio del departamento o vacío	330 valores observados	Mayúsculas y espacios simples.	No	Validación completa requiere catálogo municipal oficial.
establecimiento	Nombre oficial del establecimiento.	Texto	Texto libre	Nombres observados	Se eliminaron espacios invisibles, múltiples y comillas envolventes.	No	Se conserva la ortografía restante.
direccion	Dirección física reportada.	Texto	Texto libre o vacío	Direcciones observadas	Se normalizaron espacios y marcadores de ausencia.	No	Puede repetirse legítimamente.
telefono_principal	Número telefónico principal.	Texto	8 dígitos o vacío	Números válidos	Se conservaron ocho dígitos; inválidos quedaron vacíos.	No	Texto para conservar ceros.
supervisor	Nombre de la persona supervisora.	Texto	Nombre o vacío	Valores observados	Se normalizaron espacios; no se imputó.	No	Alta cardinalidad.
director	Nombre de la persona directora.	Texto	Nombre o vacío	Valores observados	Se normalizaron espacios; no se imputó.	No	Alta cardinalidad.
nivel	Nivel educativo autorizado.	Texto categórico	DIVERSIFICADO	DIVERSIFICADO	Se normalizó a mayúsculas.	No	Variable constante.
sector	Sector administrativo.	Texto categórico	COOPERATIVA, MUNICIPAL, OFICIAL, PRIVADO	4 categorías	Mayúsculas y validación de dominio.	No	
area	Área geográfica.	Texto categórico	RURAL, URBANA, SIN ESPECIFICAR	3 categorías	Mayúsculas y validación de dominio.	No	
estado_establecimiento	Estado de funcionamiento.	Texto categórico	Cinco categorías permitidas	5 categorías	Renombrada desde STATUS; normalizada y validada.	No	
modalidad	Modalidad lingüística.	Texto categórico	BILINGUE, MONOLINGUE	2 categorías	Mayúsculas y validación.	No	
jornada	Jornada del servicio.	Texto categórico	Seis categorías permitidas	6 categorías	Mayúsculas y validación.	No	
plan	Plan de estudios o frecuencia.	Texto categórico	Categorías observadas	13 categorías	Mayúsculas y espacios simples.	No	
direccion_departamental	Dirección Departamental responsable.	Texto categórico	Categorías observadas	26 categorías	Renombrada desde DEPARTAMENTAL y normalizada.	No	Guatemala y Quiché tienen subdivisiones.
telefono_valido	Indica si el teléfono tiene ocho dígitos válidos.	Booleano	True o False	True, False	Calculada después de limpiar el teléfono.	Sí	Apoya filtros y validación.
posible_duplicado	Marca registros para revisión por similitud parcial.	Booleano	True o False	True, False	Coincidencia de identificadores y servicio; no elimina registros.	Sí	1,451 registros marcados.

Registro de transformaciones

Variable	Problema detectado	Transformación	Registros afectados	Justificación
Todas las variables de texto	Espacios externos, múltiples e invisibles	Se aplicó trim, reducción de espacios múltiples y eliminación de caracteres de control.	115454	Uniforma el formato sin alterar el contenido semántico.
Todas las variables de texto	Marcadores de ausencia heterogéneos	Se convirtieron N/A, NA, NULL, -, --, .., SIN DATO y cadenas vacías a celdas vacías en CSV.	187	Permite interpretar los faltantes de forma consistente al importar el archivo.
Registro completo	Registros duplicados exactos	Se conservó una sola copia de cada fila idéntica.	21	Evita doble conteo sin fusionar registros parcialmente semejantes.
TELEFONO	Espacios, signos y longitudes distintas de ocho dígitos	Se conservaron únicamente ocho dígitos; los valores inválidos quedaron vacíos y se creó telefono_valido.	165	Los teléfonos guatemaltecos del conjunto deben tener ocho dígitos; no se imputaron números.
Variables categóricas y geográficas	Diferencias de mayúsculas/minúsculas y espacios	Se estandarizaron a mayúsculas y espacios simples.	0	Evita categorías duplicadas por escritura.
ESTABLECIMIENTO/DIR ECCION/TELEFONO	Posibles duplicados parciales	Se creó posible_duplicado mediante coincidencias de nombre-municipio, nombre-dirección, teléfono y similitud de nombre ≥ 0.96 .	1451	La guía prohíbe eliminar automáticamente posibles duplicados; se marcan para revisión.
Nombres de variables	Nombres originales en mayúsculas y algunos poco descriptivos	Se renombraron en snake_case; STATUS pasó a estado_establecimiento y DEPARTAMENTAL a direccion_departamental.	17	Facilita su uso en R/Python y mejora la interpretación.

Comparación de calidad antes y después

Métrica	Antes	Después	Explicación
Registros	9728	9707	Se eliminaron 21 duplicados exactos.
Variables	17	19	Se agregaron telefono_valido y posible_duplicado.
Valores faltantes	3116	2922	Se estandarizaron marcadores de ausencia; los teléfonos inválidos quedaron vacíos.
Variables con NA	17	17	Conteo de variables con al menos una celda vacía.
Duplicados exactos	21	0	Se conservaron registros únicos.
Posibles duplicados	No calculado	1451	Se marcaron, no se eliminaron automáticamente.
Variables con formato inconsistente	17	0	Se normalizaron textos, categorías, códigos y teléfonos.
Variables con tipo incorrecto	17	0	Las variables identificadoras se mantienen como texto; las derivadas son booleanas.
Categorías inconsistentes	No cuantificado	0	Se estandarizó escritura y se validaron departamentos.
Errores corregidos	No aplica	117295	Suma de registros/celdas afectados por transformaciones documentadas.

Resultado de validación: el archivo final aprobó las pruebas de estructura, duplicados exactos, espacios externos, formatos telefónicos, catálogo departamental, dominios categóricos y formato de códigos. Se conservan un registro sin código y un registro sin departamento porque contienen información restante y no existe base objetiva para imputarlos.