

Proyecto 1: Obtención y Limpieza de Datos

Partes 9 y 10

Nombre del estudiante: _____

Semestre II, 2026

Índice

1. Parte 9: Generación del conjunto limpio	2
1.1. Objetivo	2
1.2. Proceso de generación	2
1.3. Resultados	3
1.4. Variables derivadas	3
1.5. Validación automática	3
1.6. Archivos generados	4
2. Parte 10: Libro de códigos	4
2.1. Objetivo	4
2.2. Metadatos generales	4
2.3. Descripción de variables	5
2.4. Tratamientos aplicados	6
3. Reproducibilidad	6

1. Parte 9: Generación del conjunto limpio

1.1. Objetivo

Se generó un único conjunto de datos con la información correspondiente a los establecimientos educativos del país hasta el nivel diversificado. El archivo final cumple con una estructura uniforme, nombres descriptivos, tipos de datos consistentes y ausencia de los errores detectados durante la validación automática.

El conjunto final fue guardado con el nombre:

`DATOS_LIMPIOS.csv`

1.2. Proceso de generación

El proceso fue implementado en el archivo `scripts/generar_datos_limpios.py`. Las operaciones principales fueron:

1. Carga de los datos crudos mediante el módulo `csv`.
2. Verificación de que cada registro tuviera las 17 variables esperadas.
3. Estandarización de cadenas vacías y marcadores de ausencia.
4. Eliminación de espacios iniciales, finales, múltiples y caracteres invisibles.
5. Normalización de variables categóricas y geográficas.
6. Limpieza y validación del formato de los números telefónicos.
7. Eliminación de registros duplicados exactos.
8. Identificación de posibles duplicados parciales sin eliminarlos automáticamente.
9. Renombramiento de variables mediante el formato *snake_case*.
10. Creación de las variables derivadas `telefono_valido` y `posible_duplicado`.
11. Exportación del conjunto limpio y de los archivos de documentación.

1.3. Resultados

Cuadro 1: Resumen del conjunto antes y después de la limpieza

Métrica	Antes	Después
Registros	9,728	9,707
Variables	17	19
Valores faltantes	2,998	2,802
Variables con valores faltantes	17	17
Duplicados exactos	21	0
Posibles duplicados marcados	No calculado	7,309
Variables con formato inconsistente	17	0
Variables con tipo incorrecto	17	0
Categorías inconsistentes	No cuantificado	0

Los 21 registros duplicados exactos fueron eliminados, conservando una sola copia de cada fila idéntica. Los posibles duplicados parciales no fueron eliminados, debido a que la guía del proyecto exige analizarlos y documentarlos antes de tomar una decisión. Estos registros fueron identificados mediante la variable booleana `posible_duplicado`.

1.4. Variables derivadas

`telefono_valido`: indica si el número almacenado en `telefono_principal` contiene exactamente ocho dígitos y no corresponde a una secuencia evidentemente inválida.

`posible_duplicado`: identifica registros que presentan coincidencias relevantes en el nombre del establecimiento, dirección, teléfono, municipio, jornada o plan. Esta variable facilita la revisión manual sin eliminar información automáticamente.

1.5. Validación automática

La validación fue implementada en `scripts/validar_datos_limpios.py`. Las pruebas comprueban:

- estructura final de 19 columnas;
- ausencia de duplicados exactos;
- ausencia de espacios al inicio o final;
- formato de ocho dígitos en teléfonos no vacíos;
- consistencia de la variable `telefono_valido`;
- pertenencia de los departamentos al catálogo nacional;
- cumplimiento de los dominios definidos para las variables categóricas;

- formato correcto de los códigos de establecimiento.

El conjunto final aprobó las pruebas automáticas. Los registros sin código o sin departamento fueron conservados debido a que no existe evidencia suficiente para imputar esos valores y contienen información útil en las demás variables.

1.6. Archivos generados

- `datos/DATOS_LIMPIOS.csv`
- `datos/registro_transformaciones_final.csv`
- `datos/metricas_calidad.csv`
- `scripts/generar_datos_limpios.py`
- `scripts/validar_datos_limpios.py`

2. Parte 10: Libro de códigos

2.1. Objetivo

El Libro de Códigos documenta las variables incluidas en el conjunto limpio y proporciona los metadatos necesarios para comprender, validar y reutilizar los datos. Para cada variable se incluye su descripción, tipo de dato, dominio permitido, valores posibles, tratamiento aplicado durante la limpieza y condición de variable derivada.

2.2. Metadatos generales

Campo	Valor
Nombre del conjunto	DATOS_LIMPIOS.csv
Versión	1.0
Fecha de generación	23 de julio de 2026
Fecha de extracción	Pendiente de confirmación por el grupo
Fuente	Ministerio de Educación de Guatemala, búsqueda de establecimientos educativos
Cobertura	Establecimientos educativos de Guatemala hasta el nivel diversificado
Registros finales	9,707
Variables finales	19
Codificación	UTF-8 con BOM
Separador	Coma

2.3. Descripción de variables

Variable	Descripción	Tipo	Dominio o formato
codigo_establecimiento	Código oficial del servicio educativo autorizado.	Texto	Formato NN-NN-NNNN-NN o vacío.
distrito	Código del distrito de supervisión educativa.	Texto	Código alfanumérico o vacío.
departamento	Departamento donde se ubica el establecimiento.	Categórica	Uno de los 22 departamentos o vacío.
municipio	Municipio donde se ubica el establecimiento.	Categórica	Municipio correspondiente al departamento o vacío.
establecimiento	Nombre oficial del establecimiento educativo.	Texto	Texto libre.
direccion	Dirección física reportada para el establecimiento.	Texto	Texto libre o vacío.
telefono_principal	Número telefónico principal del establecimiento.	Texto	Exactamente ocho dígitos o vacío.
supervisor	Nombre de la persona responsable de supervisión.	Texto	Nombre libre o vacío.
director	Nombre de la persona directora del establecimiento.	Texto	Nombre libre o vacío.
nivel	Nivel educativo autorizado.	Categórica	DIVERSIFICADO.
sector	Sector administrativo del establecimiento.	Categórica	COOPERATIVA, MUNICIPAL, OFICIAL, PRIVADO.
area	Área geográfica del establecimiento.	Categórica	RURAL, URBANA, SIN ESPECIFICAR.
estado_establecimiento	Estado de funcionamiento reportado.	Categórica	Categorías de estado observadas y validadas.
modalidad	Modalidad lingüística del servicio.	Categórica	BILINGUE o MONOLINGUE.
jornada	Jornada en la que funciona el servicio.	Categórica	Doble, intermedia, matutina, nocturna, sin jornada o vespertina.
plan	Plan de estudios o frecuencia de atención.	Categórica	Categorías observadas en la fuente.
direccion_departamental	Dirección Departamental de Educación responsable.	Categórica	Direcciones departamentales observadas.
telefono_valido	Indica si el teléfono cumple el formato esperado.	Booleano	True o False.
posible_duplicado	Marca registros que requieren revisión por similitud parcial.	Booleano	True o False.

2.4. Tratamientos aplicados

Los tratamientos detallados se encuentran en `datos/registro_transformaciones_final.csv`. Entre las principales transformaciones se incluyen:

- eliminación de espacios externos, múltiples y caracteres invisibles;
- conversión de marcadores de ausencia a valores vacíos;
- normalización de variables categóricas;
- validación de teléfonos;
- eliminación de duplicados exactos;
- identificación de duplicados parciales;
- renombramiento descriptivo de variables;
- creación y documentación de variables derivadas.

El Libro de Códigos completo también se entrega en los archivos:

- `docs/Libro_de_Codigos.pdf`
- `docs/Libro_de_Codigos.xlsx`

3. Reproducibilidad

Para reproducir la parte 9 desde la raíz del repositorio se ejecuta:

```
python scripts/generar_datos_limpios.py
python scripts/validar_datos_limpios.py
```

El archivo crudo debe encontrarse en:

`datos/DATOS_CRUDOS.csv`

Los resultados serán generados dentro de la carpeta `datos`.